

Aprendizaje No Supervisado aplicado a Indicadores Educativos Globales UNESCO

Maestría en Inteligencia Artificial

Asignatura: Aprendizaje Automático

Análisis No Supervisado

Pregunta de investigación:

¿Es posible identificar grupos naturales de países con perfiles educativos similares, y cómo difieren los patrones encontrados según el método de aprendizaje no supervisado utilizado?

Fuente de datos: UNESCO Institute for Statistics (UIS) | Cobertura: 210 países · 2000–2022

Modelos: K-Means · DBSCAN · PCA · t-SNE

Grupo N°5

- Harold Angulo
- Melisa Figallo
- Jorge Maldonado
- Paula Noboa

Mayo 2026

Resumen

Este informe presenta un análisis comparativo de cuatro métodos de aprendizaje no supervisado aplicados a datos de matrícula escolar de 207 países, provenientes del Instituto de Estadística de la UNESCO. Los resultados muestran que existen grupos naturales y bien diferenciados en los sistemas educativos globales, siendo el nivel de cobertura de la educación secundaria la principal dimensión que separa a los países.

Modelo	Clusters	Silhouette	Davies-Bouldin	Rol principal
K-Means (k=2)	2 clusters	0.4833	0.9533	Segmentación
DBSCAN(eps=1.1,ms=5)	2 + 31 outliers	0.5328	0.5764	Detección de anomalías
PCA (2 componentes)	—	91.3% var. expl.	—	Reducción / visualización
t-SNE (perp=30)	—	Visual	—	Validación visual

Tabla 0.1 — Resumen comparativo de los cuatro métodos de aprendizaje no supervisado aplicados.

1. Introducción

La educación es uno de los indicadores más representativos del nivel de desarrollo de una sociedad. Sin embargo, comparar sistemas educativos entre países es un reto complejo: las diferencias culturales, económicas y geográficas producen patrones de matrícula muy distintos entre regiones. En este contexto, las técnicas de aprendizaje no supervisado ofrecen una herramienta poderosa: permiten descubrir agrupaciones naturales en los datos sin necesidad de definir etiquetas o categorías a priori.

El presente informe aplica cuatro métodos complementarios — K-Means, DBSCAN, PCA y t-SNE — sobre indicadores educativos de la UNESCO para responder a la pregunta: ¿existen grupos naturales de países con perfiles educativos similares, y cómo difieren los hallazgos según el método utilizado?

1.1 Justificación del Dataset

El dataset fue construido a partir del Instituto de Estadística de la UNESCO (UIS, acceso abril 2023) y contiene tasas brutas de matrícula escolar desagregadas por nivel educativo (primaria, secundaria baja, secundaria alta) y género (hombres y mujeres), para 210 países entre los años 2000 y 2022.

La elección de este conjunto de datos responde a tres criterios metodológicos:

- Multidimensionalidad controlada: 6 variables numéricas que capturan la misma dimensión (cobertura educativa) desde distintos ángulos (nivel y género), facilitando la interpretación de los clusters.
- Cobertura global: 210 países representan prácticamente todos los sistemas educativos del mundo, lo que garantiza variabilidad real en los datos.
- Pertinencia para el aprendizaje no supervisado: no existe una clasificación oficial de "tipos de sistemas educativos", lo que convierte a este problema en un caso ideal para descubrir estructura latente sin etiquetas previas.

Las tasas de matrícula brutas son ideales para comparaciones internacionales porque están normalizadas respecto a la población en edad escolar, eliminando el efecto del tamaño del país. Valores superiores a 100% son posibles y esperables en la metodología UNESCO, ya que incluyen estudiantes fuera del rango etario oficial (repitentes, personas con acceso tardío).

1.2 Objetivos Específicos

- Explorar la distribución y atipicidades de los indicadores educativos a nivel global.
- Identificar agrupaciones naturales de países mediante K-Means, seleccionando el número óptimo de clusters con el método del codo y el Silhouette Score.
- Detectar países con perfiles educativos atípicos (outliers genuinos) mediante DBSCAN.
- Reducir la dimensionalidad del dataset con PCA para identificar las dimensiones latentes que estructuran los sistemas educativos globales.
- Validar visualmente las agrupaciones con t-SNE, evaluando el impacto de distintos valores de perplejidad.
- Comparar cuantitativa y cualitativamente los resultados de los cuatro métodos para responder a la pregunta de investigación.

2. Descripción del Dataset y Análisis Exploratorio

2.1 Estructura Original del Dataset

El archivo datos_educativos.csv tiene estructura de formato largo: cada fila representa una observación puntual de un país en un año para un indicador concreto.

Campo		Tipo	Descripción
Índice		Entero	Identificador secuencial de fila
ID		Entero	Identificador único por país
País		Texto	Nombre oficial del país o territorio (210 únicos)
Año		Entero	Año de registro (2000 – 2022)
Tipo de Educativo	Dato	Texto	Indicador: 9 tipos distintos (6 tasas + 3 volúmenes)
Tasa		Decimal	Valor numérico del indicador (puede superar 100% en tasas brutas)
Fuente Datos		Texto	UNESCO Institute for Statistics (UIS)

Tabla 2.1 — Estructura del archivo datos_educativos.csv (5,765 filas × 7 columnas).

DATASET Y ANÁLISIS EXPLORATORIO																															
Fuente de Datos Institución: UNESCO Institute for Statistics (UIS) Cobertura: 210 países · 2000–2022 Registros: 5.765 observaciones Formato: Long format → pivotado a wide Indicadores: Matrícula bruta primaria y secundaria por género Variables: Prim_H, Prim_M, SecBaja_H, SecBaja_M, SecAlta_H, SecAlta_M Imputación: Mediana global (mínimo 4/6 features) Escala: StandardScaler (media=0, $\sigma=1$)		Estadísticas Descriptivas de los 6 Indicadores <table> <tr> <th>Variable</th><th>Media</th><th>Desv.Est</th><th>CV (%)</th></tr> <tr> <td>Prim_H</td><td>104.9</td><td>12.8</td><td>12.2</td></tr> <tr> <td>Prim_M</td><td>102.1</td><td>14.0</td><td>13.7</td></tr> <tr> <td>SecBaja_H</td><td>88.7</td><td>25.2</td><td>28.4</td></tr> <tr> <td>SecBaja_M</td><td>87.2</td><td>27.5</td><td>31.5</td></tr> <tr> <td>SecAlta_H</td><td>73.4</td><td>34.4</td><td>46.9</td></tr> <tr> <td>SecAlta_M</td><td>75.5</td><td>36.7</td><td>48.6</td></tr> </table>		Variable	Media	Desv.Est	CV (%)	Prim_H	104.9	12.8	12.2	Prim_M	102.1	14.0	13.7	SecBaja_H	88.7	25.2	28.4	SecBaja_M	87.2	27.5	31.5	SecAlta_H	73.4	34.4	46.9	SecAlta_M	75.5	36.7	48.6
Variable	Media	Desv.Est	CV (%)																												
Prim_H	104.9	12.8	12.2																												
Prim_M	102.1	14.0	13.7																												
SecBaja_H	88.7	25.2	28.4																												
SecBaja_M	87.2	27.5	31.5																												
SecAlta_H	73.4	34.4	46.9																												
SecAlta_M	75.5	36.7	48.6																												

Los 9 indicadores disponibles se dividen en dos grupos según su naturaleza:

- Tasas brutas de matrícula (6 indicadores, usados en el análisis): Primaria Hombres, Primaria Mujeres, Secundaria Baja Hombres, Secundaria Baja Mujeres, Secundaria Alta Hombres, Secundaria Alta Mujeres.
- Volúmenes absolutos (3 indicadores, excluidos del clustering): Estudiantes Primaria en miles, Estudiantes Secundaria Baja en miles, Estudiantes Secundaria Alta en miles.

Los volúmenes absolutos se excluyen del análisis de clustering porque dependen del tamaño poblacional del país, no de su eficiencia o cobertura educativa. Un país grande con cobertura baja podría quedar agrupado junto a un país pequeño con cobertura alta si se usaran valores absolutos.

2.2 Hallazgos Exploratorios Clave

Distribuciones y Atipicidades

La siguiente tabla resume los estadísticos descriptivos de las 6 tasas de matrícula (valores calculados como promedio por país sobre todos los años disponibles, 207 países finales):

Variable	Media	Mediana	Desv. Est.	Mínimo	Máximo	Sesgo	Outliers	CV (%)
Prim_H	104.9	107.6	12.8	30.1	143.6	-0.75	13	12.2
Prim_M	102.1	104.9	14.0	16.6	150.0	-1.15	26	13.7
SecBaja_H	88.7	97.0	25.2	10.2	182.1	-0.62	14	28.4
SecBaja_M	87.2	94.8	27.5	4.7	170.0	-0.87	17	31.5
SecAlta_H	73.4	74.1	34.4	6.9	215.2	+0.48	2	46.9
SecAlta_M	75.5	76.3	36.7	3.2	193.6	+0.03	2	48.6

Tabla 2.2 — Estadísticas descriptivas de las 6 tasas de matrícula (n=207 países). CV = Coeficiente de Variación.

Los hallazgos más importantes del análisis exploratorio son:

- Primaria: distribución sesgada hacia la izquierda (sesgo negativo). La mayoría de los países tiene tasas cercanas o superiores al 100%, lo que indica cobertura casi universal a nivel global. Sin embargo, los 13–26 outliers detectados representan países con tasas muy bajas (mínimos de 16.6% en mujeres), revelando exclusión educativa severa.
- Secundaria baja: mayor dispersión (CV $\approx$ 29–32%). El rango va desde 4.7% hasta 182.1%, lo que indica enormes diferencias en la cobertura de la educación media entre países. Los sesgos negativos confirman que hay un grupo dominante de países con buena cobertura y una cola de países rezagados.
- Secundaria alta: indicador más heterogéneo (CV $\approx$ 47–49%). El sesgo se vuelve positivo, mostrando que la distribución está más equilibrada, pero con valores extremos en ambas direcciones. Los valores máximos superando 200% se explican por países donde muchos adultos regresan al sistema educativo.
- Brecha de género: se evidencia especialmente en secundaria baja y alta. En primaria la diferencia media es de 2.8 puntos, pero en secundaria alta, en algunos países de África subsahariana y Asia meridional, la brecha puede superar 20 puntos porcentuales.

Correlaciones entre Indicadores

La matriz de correlaciones de Pearson revela patrones muy informativos para el análisis de clustering:

MATRIZ DE CORRELACIÓN DE INDICADORES EDUCATIVOS POR GÉNERO

Prim_H	1.00	0.91	0.22	0.21	0.02	0.06
Prim_M	0.91	1.00	0.39	0.42	0.19	0.26
SecBaj_H	0.22	0.39	1.00	0.97	0.74	0.80
SecBaj_M	0.21	0.42	0.97	1.00	0.73	0.81
SecAlt_H	0.06	0.19	0.74	0.73	1.00	0.96
SecAlt_M	0.06	0.26	0.80	0.81	0.96	1.00

Tabla 2.3 — Matriz de correlaciones de Pearson entre los 6 indicadores de matrícula (n=207).

Tres patrones de correlación se destacan:

- Correlación muy alta entre géneros dentro del mismo nivel: Prim_H/Prim_M = 0.91, SecBaja_H/SecBaja_M = 0.97, SecAlta_H/SecAlta_M = 0.96. Esto indica que los países invierten en educación de manera similar para ambos géneros a cada nivel.
- Correlación moderada entre niveles contiguos: SecBaja ↔ SecAlta (0.73–0.81). Los países con buena secundaria baja tienden a tener también buena secundaria alta, pero la correlación no es perfecta, lo que permite distinguir países con retención escolar alta vs. baja.
- Correlación débil entre primaria y secundaria alta: Prim_H/SecAlta_H = 0.02, Prim_M/SecAlta_M = 0.26. Este es el hallazgo más crítico: garantizar la educación primaria NO implica necesariamente que los estudiantes lleguen a la secundaria alta. Existen países con cobertura primaria casi universal, pero con abandono masivo antes de la secundaria.

Conclusión del EDA: Los datos presentan dos dimensiones naturales. (1) el nivel general de cobertura del sistema educativo y (2) la brecha entre género o entre niveles educativos. Estas dimensiones serán confirmadas por el PCA.

3. Preprocesamiento — Diseño de Decisiones

El preprocesamiento es la etapa más crítica del análisis no supervisado. Las decisiones tomadas en esta fase determinan directamente qué estructura pueden encontrar los algoritmos. A continuación, se detallan las cuatro decisiones clave y su justificación.

3.1 Transformación de Formato Largo a Ancho

El dataset original está en formato largo: cada fila es una observación (país × año × indicador). Los algoritmos de clustering requieren formato ancho: cada fila es un país y cada columna es una característica numérica.

La transformación se realizó en dos pasos:

- Paso 1 — Filtrado: se retuvieron únicamente las 6 tasas de matrícula, descartando los 3 indicadores de volumen absoluto (estudiantes en miles).
- Paso 2 — Pivote y agregación temporal: se calculó la media por país sobre todos los años disponibles (2000–2022). Esto maximiza la cobertura geográfica (si un país reportó datos solo en algunos años, igualmente aparece en el dataset) y suaviza fluctuaciones anuales por cambios de metodología en el reporte.

Resultado de la transformación:

- Formato original: 5,765 filas × 7 columnas
- Formato ancho (antes del filtro): 208 países × 6 features
- Formato final (después del filtro de calidad): 207 países × 6 features

3.2 Filtro de Calidad y Umbral de Completitud

Se eliminaron los países con menos de 4 de 6 features disponibles (es decir, con más de 2 indicadores sin ningún dato en todo el período 2000–2022). Este umbral se eligió porque:

- Con 4+ features, el vector de características del país es suficientemente representativo para calcular distancias euclidianas significativas.
- Un umbral más restrictivo (6/6) eliminaría demasiados países de bajo reporte, precisamente los que pueden tener los perfiles más interesantes para el análisis.

Resultado: se eliminó 1 país (de 208 a 207). Los valores faltantes restantes se imputaron con la mediana global de cada feature, una estrategia robusta ante distribuciones con outliers.

3.3 Estandarización con StandardScaler

Antes de aplicar cualquier algoritmo basado en distancias euclidianas (K-Means y DBSCAN), se estandarizaron las 6 features con StandardScaler:

- Fórmula: $z = (x - \text{media}) / \text{desviación_estándar}$ para cada columna.
- Resultado: cada feature tiene media = 0 y desviación estándar = 1.

Sin estandarizar (problema)	Con StandardScaler (solución)
Prim_H oscila entre 30 y 144 (rango: 114 pts)	Todas las features con rango comparable ($\sim \pm 3$)
SecAlta_H oscila entre 7 y 215 (rango: 208 pts)	Ninguna variable domina el cálculo de distancias
SecAlta tendría 2x más peso que Primaria en KMeans	El clustering refleja patrones reales, no diferencias de escala

Tabla 3.1 — Impacto de la estandarización en los algoritmos basados en distancias.

4. K-Means Clustering

4.1 Fundamentos del Algoritmo

K-Means es el algoritmo de clustering más utilizado en aprendizaje no supervisado. Su objetivo es dividir n observaciones en k grupos, minimizando la suma de distancias al cuadrado de cada punto a su centroide (inercia o WCSS — Within-Cluster Sum of Squares).

El algoritmo funciona de forma iterativa:

- Inicialización: se colocan k centroides iniciales usando la estrategia k-means++ (distribuye los centroides de forma más inteligente que aleatoria, reduciendo el riesgo de convergencia a mínimos locales).
- Asignación: cada país se asigna al centroide más cercano (menor distancia euclidiana).
- Actualización: cada centroide se recalcula como la media de todos los países asignados a su grupo.
- Convergencia: los pasos 2–3 se repiten hasta que las asignaciones no cambian entre iteraciones.

Parámetros usados: `n_init="auto"` (múltiples inicializaciones para evitar mínimos locales), `random_state=42` (reproducibilidad).

4.2 Selección del Número Óptimo de Clusters

Método del Codo (Elbow Method)

El método del codo grafica la inercia (suma de distancias cuadradas al centroide) para diferentes valores de k . A medida que k aumenta, la inercia siempre disminuye, pero la ganancia marginal se reduce. El "codo" visual indica el punto donde agregar más clusters aporta poco beneficio adicional.

k	Inercia	Reducción vs k1	Silhouette	Davies-Bouldin	Observación
2	717.1	—	0.4833	0.9533	OPTIMO
3	522.3	-27.2%	0.4355	—	Baja el silhouette
4	435.1	-16.7%	0.2645	—	Codo visible
5	385.2	-11.5%	0.2937	—	Ganancia marginal
6	344.9	-10.5%	0.2861	—	Diminishing returns
7	328.7	-4.7%	0.2950	—	Reducción mínima
8–10	<300	<10%	<0.33	—	Sobreajuste

Tabla 4.1 — Evolución de inercia y Silhouette Score para $k=2$ a 10 en el dataset educativo UNESCO.

Silhouette Score

El Silhouette Score mide la calidad de un clustering comparando para cada punto: qué tan cohesionado está con su propio cluster (a) vs. qué tan separado está del cluster más cercano (b). La fórmula es $s = (b - a) / \max(a, b)$, con rango $[-1, 1]$ donde valores cercanos a 1 indican clusters compactos y bien separados.


Resultado: $k=2$ obtiene el Silhouette Score más alto (0.4833), indicando que la partición más natural de los datos educativos globales es en DOS grupos principales. El codo en la curva de inercia también se observa claramente en $k=3-4$, pero ninguno supera la calidad de $k=2$.

Distribución final del modelo K-Means con $k=2$:

Cluster	Prim_H (%)	Prim_M (%)	SecBaja_H (%)	SecBaja_M (%)	SecAlta_H (%)	N
Cluster 0 — Alta cobertura	105.4	104.3	100.7	100.9	87.4	154
Cluster 1 — Baja cobertura	103.4	95.7	53.9	47.4	32.6	53

Tabla 4.2 — Perfiles medios de los clusters K-Means. Nótese la diferencia dramática en secundaria.

Comparación de Centroides por Indicador



Perfiles de Clusters ($k=2$)

Cluster 0 — Alta Cobertura

N=154 países (74%) · Primaria~105% · SecBaja~101% · SecAlta~87%

Cluster 1 — Baja Cobertura

N=53 países (26%) · Primaria~103% · SecBaja~51% · SecAlta~32%

Ejemplos de países por cluster:

- Cluster 0 (alta cobertura, 154 países): Argentina, Albania, Armenia, China-HK, Algeria, Antigua y Barbuda... En general incluye países de Europa, América Latina, Asia Oriental y Oriente Medio.
- Cluster 1 (baja cobertura, 53 países): Afghanistan, Angola, Bangladesh, Benin, Burkina Faso, Burundi, Cambodia, Cameroon... Principalmente países de África Subsahariana y Asia Meridional.

4.3 Limitaciones de K-Means en este Contexto

- Forma esférica obligatoria: K-Means asume que los clusters son convexos y de tamaño similar. Los datos educativos pueden contener formas irregulares que K-Means no puede capturar.
- Forzamiento de pertenencia: todo país debe pertenecer a algún cluster, incluso los outliers genuinos (como países con perfiles educativos únicos). DBSCAN resolverá este problema.
- Sensibilidad a la escala: aunque mitigada por la estandarización, la elección de features afecta los centroides.
- Interpretación de $k=2$ muy simple: dos grupos grandes pueden ocultar subgrupos internos relevantes (diferencias dentro de los países "en desarrollo" o entre países "desarrollados").

5. DBSCAN — Clustering Basado en Densidad

5.1 Fundamentos del Algoritmo

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo que agrupa puntos en regiones de alta densidad, separadas por regiones de baja densidad. A diferencia de KMeans, no requiere especificar el número de clusters a priori y puede detectar formas arbitrarias.

Los tres tipos de puntos en DBSCAN:

- Punto núcleo (core point): tiene al menos `min_samples` vecinos dentro de un radio `eps`. Es el centro de un cluster.
- Punto de borde (border point): está dentro del radio `eps` de un punto núcleo pero no tiene suficientes vecinos propios. Pertenece al cluster pero no lo expande.
- Punto de ruido (noise point, etiqueta = -1): no es núcleo ni borde. Representa un outlier genuino que no pertenece a ningún cluster denso.

La ventaja clave de DBSCAN en este contexto es precisamente la capacidad de identificar países "atípicos" que K-Means no puede detectar, ya que K-Means obliga a todos los países a pertenecer a un grupo.

5.2 Selección de Parámetros

K-Distance Graph para Selección de eps

El K-Distance Graph es el método estándar para seleccionar el parámetro `eps`. Para cada punto se calcula la distancia a su `k`-ésimo vecino más cercano ($k = \text{min_samples}$). Los puntos de baja densidad tendrán distancias grandes. Al graficar estas distancias en orden, el "codo" indica la separación natural entre puntos densos (clusters) y puntos dispersos (ruido).

Con `min_samples = 5`, la regla práctica da: `eps` sugerido $\approx$ distancia promedio a 5-ésimo vecino en los datos. Este valor fue la semilla para el grid search.

Grid Search sobre `eps` × `min_samples`

Se realizó una búsqueda exhaustiva sobre la grilla $\text{eps} \in [0.3, 2.0]$ (paso 0.1) × $\text{min_samples} \in \{3, 5, 7, 10\}$, evaluando únicamente configuraciones con 2–8 clusters y menos del 40% de puntos como ruido.

eps	min_samples	N Clusters	N Ruido	% Ruido	Silhouette
1.1	5	2	31	15.0%	0.5328 ★
1.0	5	2	33	15.9%	0.5219
1.2	5	2	25	12.1%	0.5105
1.1	7	2	38	18.4%	0.5071
0.9	5	2	41	19.8%	0.4987

Tabla 5.1 — Top 5 configuraciones del grid search DBSCAN. ★ = configuración seleccionada.

5.3 Regla Práctica para min_samples

La regla general para min_samples es: $\text{min_samples} = 2 \times \text{número_de_dimensiones}$. Con 6 features, esto sugiere $\text{min_samples} = 12$. Sin embargo, en práctica, con datos reales y heterogéneos se usa min_samples más pequeño para no excluir sub-regiones legítimas. El grid search validó que $\text{min_samples}=5$ produce los mejores resultados con los datos de la UNESCO.

Resultados finales del modelo DBSCAN ($\text{eps}=1.1$, $\text{min_samples}=5$):

- 2 clusters genuinos (países con perfiles similares entre sí)
- 31 países identificados como ruido (15.0% del total) — outliers con perfiles educativos únicos

 Países outliers Identificados como ruido (outliers genuinos) · DBSCAN $\text{eps}=1.1$ · $\text{min_samples}=5$		
01 ● Afghanistan	02 ● Australia	03 ● Australia and New Zealand
04 ● Belgium	05 ● Burundi	06 ● Central African Republic
07 ● Curaçao	08 ● Côte d'Ivoire	09 ● Djibouti
10 ● Equatorial Guinea	11 ● Eritrea	12 ● Gambia
13 ● Guinea-Bissau	14 ● Honduras	15 ● Madagascar
16 ● Malawi	17 ● Mauritania	18 ● Monaco
19 ● Montserrat	20 ● Mozambique	21 ● Niger
22 ● Papua New Guinea	23 ● Rwanda	24 ● Sierra Leone
25 ● Sint Maarten (Dutch part)	26 ● Somalia	27 ● South Sudan
28 ● Tokelau	29 ● Uganda	30 ● United Rep. of Tanzania
31 ● Zambia		
31 países etiquetados como ruido — perfiles educativos extremos o micro-territorios no asimilables a ningún cluster.		

DBSCAN supera a K-Means en Silhouette Score (0.5328 vs 0.4833) porque no fuerza a los outliers a pertenecer a un cluster, lo que mejora la cohesión interna. Los 31 países ruidosos son precisamente los "casos difíciles" que K-Means habría agrupado de forma artificial.

De los 31 países identificados como ruido (outliers), se analizó e investigó el por qué y se generó la revisión de algunos de ellos y se obtuvo lo siguiente:

Australia(Análisis de atipicidad):

Causa técnica: Australia reporta tasas netas de matrícula (excluye repitentes y fuera de edad), mientras que la mayoría de países reporta tasas brutas. Esto produce valores artificialmente bajos (~95%) que el scaler interpreta como cobertura media, alejándola de sus vecinos OCDE que reportan valores brutos >110%.

Bélgica(Análisis de atipicidad)

Causa técnica: El sistema educativo belga tiene tres redes (neerlandófono, francófono y germanófono) que reportan inscripciones de forma independiente. Un alumno en una escuela bilingüe puede aparecer en dos redes, inflando la tasa bruta de secundaria alta a >130%. Se recomendaría la Unesco solicitar a Bélgica un identificador único de alumno (student ID)

Sudán del Sur (Análisis de atipicidad)

Causa técnica: País reconocido en 2011; los datos anteriores están agregados con Sudán. Desde 2011, los conflictos internos interrumpieron los censos educativos. Solo hay 4 puntos de datos en 22 años, todos imputados con mediana global. Marcar explícitamente los países con < 5 años de datos reales como "datos insuficientes".

6. PCA — Análisis de Componentes Principales

6.1 Fundamentos y Doble Rol en el Análisis

El Análisis de Componentes Principales (PCA) es una técnica de reducción de dimensionalidad lineal que transforma las variables originales en combinaciones lineales ortogonales llamadas componentes principales (PC), ordenadas de mayor a menor varianza explicada.

En este análisis, PCA cumple dos roles complementarios:


- Rol analítico: revelar las dimensiones latentes que estructuran los sistemas educativos globales. Las cargas (loadings) de cada componente nos dicen qué variables originales contribuyen más a cada dimensión.
- Rol de visualización: proyectar los 207 países del espacio de 6 dimensiones a un plano 2D, permitiendo visualizar los clusters identificados por K-Means y DBSCAN de forma comprensible.

6.2 Varianza Explicada y Selección de Componentes

Componente	Varianza explicada	Varianza acumulada	Interpretación
PC1	62.3%	62.3%	Desarrollo educativo general
PC2	29.0%	91.3%	Brecha primaria vs. secundaria
PC3	6.3%	97.6%	Variación residual menor
PC4	1.4%	99.1%	Ruido / micro diferencias
PC5+PC6	0.9%	100.0%	Residual mínimo

Tabla 6.1 — Varianza explicada por componente principal (n=207 países, 6 features).

Solo 2 componentes principales explican el 91.3% de toda la varianza del dataset. Esto significa que 6 variables con dimensión aparente pueden describirse casi completamente en 2 dimensiones. La proyección PCA captura fielmente la estructura real de los datos educativos.



6.3 Interpretación Esperada de los Componentes

Los loadings (cargas) de cada feature en PC1 y PC2 revelan qué dimensión mide cada componente:

Variable	Loading PC1	Loading PC2	Interpretación	Género
Prim_H	0.180	+0.693	PC2 domina: diferencia primaria vs. sec.	Hombres
Prim_M	0.278	+0.620	PC2 domina: diferencia primaria vs. sec.	Mujeres
SecBaja_H	+0.484	-0.076	PC1 domina: nivel de desarrollo medio	Hombres
SecBaja_M	+0.486	-0.067	PC1 domina: nivel de desarrollo medio	Mujeres
SecAlta_H	+0.445	-0.268	PC1 domina: desarrollo educativo pleno	Hombres
SecAlta_M	+0.471	-0.231	PC1 domina: desarrollo educativo pleno	Mujeres

Tabla 6.2 — Loadings de los 6 indicadores en los dos primeros componentes principales.

Interpretación de los componentes:

- PC1 — "Desarrollo educativo general": carga positiva alta en SecBaja (+0.48) y SecAlta (+0.44–0.47), carga baja en Primaria. Los países con PC1 alto tienen buena cobertura en todos los niveles, especialmente en secundaria. Países con PC1 bajo son los de bajo desarrollo educativo (principalmente África Subsahariana).
- PC2 — "Brecha entre primaria y secundaria": carga positiva alta en Primaria (0.62–0.69), carga negativa en Secundaria Alta. Países con PC2 alto tienen buena primaria pero baja secundaria — el clásico patrón de retención deficiente. Países con PC2 bajo tienen secundaria alta relativa a su primaria.

Este análisis confirma el hallazgo del EDA: las dos dimensiones principales de los sistemas educativos globales son (1) el nivel de desarrollo educativo general y (2) la brecha entre la cobertura primaria y la secundaria alta.

7. t-SNE — Visualización No Lineal

7.1 Fundamentos del Algoritmo

t-SNE (t-Distributed Stochastic Neighbor Embedding) es una técnica de reducción de dimensionalidad no lineal, diseñada específicamente para visualización en 2D o 3D. A diferencia de PCA, que preserva la estructura global (distancias entre todos los pares de puntos), t-SNE preserva la estructura local: puntos cercanos en el espacio de alta dimensión permanecen cercanos en la proyección 2D.


El algoritmo funciona en dos fases:

- Construcción de similitudes: en el espacio original (6D), se calcula para cada par de países la probabilidad de que sean "vecinos cercanos" usando distribuciones gaussianas. La perplexidad controla cuántos vecinos considera cada punto.
- Optimización en 2D: en el espacio reducido (2D), se modela la similitud con distribuciones t de Student (más colas pesadas). El algoritmo minimiza la divergencia KL entre ambas distribuciones de similitud, produciendo una disposición donde los grupos se separan visualmente.

Parámetro	Valor usado	Descripción	Impacto
perplexity	10, 30, 50	Vecinos efectivos considerados por punto	Bajo=estructura local, Alto=estructura global
learning_rate	200	Velocidad de ajuste iterativo	Valores típicos: 200–1000
max_iter	1000	Iteraciones hasta convergencia	Mínimo recomendado: 1000
random_state	42	Semilla de aleatoriedad para reproducibilidad	Sin semilla, cada ejecución produce resultados diferentes

Tabla 7.1 — Parámetros de configuración del modelo t-SNE.

Representación esquemática t-SNE (perp=30)



⚠ Las distancias entre clusters en t-SNE no son cuantitativamente interpretables — solo informa sobre separabilidad local.

7.2 Parámetros y Diseño de la Comparación

Perplejidad

La perplejidad es el parámetro más importante de t-SNE. Intuitivamente, representa el número efectivo de vecinos que cada punto considera. Se compararon tres valores:

- Perplexity=10 (baja): cada punto considera pocos vecinos, enfocándose en estructura muy local. Tiende a crear muchos grupos pequeños aislados. Puede fragmentar clusters reales.
- Perplexity=30 (estándar, seleccionado): balance entre estructura local y global. Recomendado por los autores originales del algoritmo (Maaten & Hinton, 2008) para datasets de tamaño medio.
- Perplexity=50 (alta): cada punto considera más contexto global. Puede suavizar la separación entre grupos. Adecuado para datasets muy grandes.

Rol de t-SNE en este Análisis

Es fundamental entender que t-SNE NO produce clusters — es una herramienta de visualización, no de clustering. Sus ejes 2D no tienen interpretación directa como los de PCA, y las distancias entre grupos en el plano t-SNE no son proporcionales a las distancias reales en el espacio original.

El rol correcto de t-SNE en este análisis es triple:

- Validación visual: confirmar que los clusters identificados por K-Means y DBSCAN tienen separación geométrica real en el espacio de datos.
- Detección de subgrupos: identificar posibles subestructuras internas dentro de cada cluster que los otros métodos no habían distinguido.
- Identificación visual de outliers: los puntos marcados como ruido por DBSCAN deberían aparecer en los márgenes o aislados en la proyección t-SNE.

ADVERTENCIA METODOLÓGICA: Los axes de t-SNE no tienen interpretación cuantitativa. Nunca se deben extraer conclusiones cuantitativas de las distancias en el gráfico t-SNE, solo confirmar o explorar patrones identificados por otros métodos.

8. Evaluación Comparativa de Métodos

8.1 Métricas de Evaluación

La evaluación del clustering es inherentemente más difícil que la evaluación de modelos supervisados, porque no existe una "respuesta correcta" con la que comparar. Se usan métricas internas (que miden la calidad de los clusters sin necesidad de etiquetas externas):

Métrica	Rango	Mejor valor	Qué mide
Silhouette Score	[-1, 1]	Cercano a 1	Para cada punto: qué tan bien encaja en su cluster vs. en el más cercano. Valores altos = clusters compactos y bien separados.
Davies-Bouldin Index	[0, ∞)	Cercano a 0	Similaridad promedio entre cada cluster y su más similar. Valores bajos = clusters más distintos entre sí.
Calinski-Harabasz	[0, ∞)	Mayor es mejor	Ratio entre la dispersión entre clusters (inter-cluster) y dentro de los clusters (intra-cluster). Valores altos = estructura compacta y bien separada.

Tabla 8.1 — Métricas de evaluación interna para clustering.

8.2 Concordancia entre K-Means y DBSCAN

La concordancia entre ambos métodos se evalúa a través de la tabla cruzada de asignaciones. Los principales hallazgos son:

- Los 2 clusters de K-Means corresponden aproximadamente a los 2 clusters de DBSCAN, pero DBSCAN extrae 31 países del cluster K-Means 1 (el de baja cobertura) y los reclasifica como ruido, ya que son demasiado dispersos para formar su propio cluster denso.
- Los países marcados como ruido por DBSCAN incluyen tanto países con cobertura extremadamente baja (Somalia, South Sudan, Niger) como países con perfiles atípicos por ser muy pequeños o con datos parciales (Monaco, Montserrat, Tokelau, Sint Maarten).
- Australia y Belgium aparecen como ruido porque sus perfiles son inusuales respecto al patrón general de los países de alta cobertura (posiblemente por la forma en que reportan las tasas brutas).

8.3 Tabla Comparativa de Métodos

Dimensión	K-Means	DBSCAN	PCA	t-SNE
Tipo de método	Clustering	Clustering	Reducción dim.	Reducción dim.
Produce clusters	Sí	Sí + ruido	No	No
Silhouette Score	0.4833	0.5328 ★	91.3% var.	Visual
Davies-Bouldin	0.9533	0.5764 ★	—	—
Calinski-Harabasz	150.04 ★	72.38	—	—
Clusters encontrados	2	2 + 31 outliers	—	—

Requiere K a priori	Sí	No	No		No
Manejo de outliers	Los asigna al cluster más cercano	Los marca como ruido (-1)	Los mueve al borde		Los separa visualmente
Forma de clusters	Esférica / convexa	Arbitraria (densidad)	Lineal (subespacio)		No lineal
Interpretabilidad	Alta (perfiles medios)	Media	Alta (loadings)		Baja (sin ejes)
Reproducibilidad	Alta (con random_state)	Alta (determinista)	Perfecta		Con random_state
Escalabilidad (O)	$O(nk)$ — alta	$O(n \log n)$ — media	$O(n^2p^2)$ — alta		$O(n^2)$ — baja
Uso recomendado	Segmentación, perfiles medios	Anomalías, formas irregulares	Análisis dimensional		Validación visual

Tabla 8.2 — Comparación completa de los cuatro métodos aplicados. ★ = mejor valor en su métrica.

PERFILES EDUCATIVOS IDENTIFICADOS

Cluster 0 — Alta Cobertura

154 países · 74%

📍 Europa · América Latina · Asia Oriental

Primaria ~105% · SecBaja ~101% · SecAlta 87–92%

Sistema educativo sólido con fuerte cobertura en todos los niveles

Cluster 1 — Baja Cobertura

53 países · 26%

📍 África Subsahariana · Asia Meridional

Primaria ~103% · SecBaja ~51% · SecAlta 29–33%

La caída se produce en la transición hacia la educación secundaria

Outliers DBSCAN — Ruido

31 países · 15%

📍 Dispersos globalmente

Perfiles únicos: extremos o micro-territorios

No se asimilan a ningún cluster — requieren análisis individual

Nota sobre Calinski-Harabasz: K-Means obtiene CH=150.04 vs DBSCAN CH=72.38. Esto no contradice los resultados del Silhouette. La diferencia se explica porque el CH penaliza los puntos marcados como ruido (que DBSCAN excluye) y está diseñado específicamente para clusters convexos, favoreciendo a K-Means en esta métrica.

9. Conclusiones Principales

9.1 Respuesta a la Pregunta de Investigación

¿Es posible identificar grupos naturales de países con perfiles educativos similares, y cómo difieren los patrones encontrados según el método de aprendizaje no supervisado utilizado?

Sí. Los cuatro métodos aplicados convergen en identificar una estructura de agrupación real y estadísticamente significativa en los datos educativos de la UNESCO. La estructura no es trivial ni artefacto del preprocesamiento: tiene respaldo en múltiples métricas cuantitativas (Silhouette 0.48–0.53, DaviesBouldin 0.58) y en el PCA (91.3% de la varianza explicada por solo 2 componentes).

Los cuatro métodos son complementarios — no rivales — y cada uno aporta una perspectiva diferente sobre la misma realidad educativa:

- K-Means: proporciona la segmentación más interpretable y los perfiles medios de cada grupo. Es el mejor punto de partida para describir qué tipos de sistemas educativos existen.
- DBSCAN: añade una capa de información crítica al identificar los 31 países con perfiles genuinamente atípicos que K-Means habría clasificado arbitrariamente. Responde a la pregunta "¿hay países que no encajan en ningún grupo?"
- PCA: explica POR QUÉ los clusters existen. Las dos dimensiones latentes (desarrollo general + brecha primaria/secundaria) tienen interpretación directa y justifican la estructura encontrada.
- t-SNE: valida visualmente que la separación entre clusters es real en el espacio no lineal de alta dimensión, no solo un artefacto de la proyección lineal del PCA.

9.2 Perfiles Educativos Identificados

Los dos grandes grupos identificados por K-Means y confirmados por DBSCAN son:

Perfil	N Países	Características clave	Regiones típicas
CLUSTER 0 — Alta cobertura	154 países (74%)	Primaria ≈ 105%, SecBaja ≈ 101%, SecAlta ≈ 87–92%. Continuidad educativa sólida a todos los niveles.	Europa, América Latina, Asia Oriental, Oriente Medio, Norte de África
CLUSTER 1 — Baja cobertura	53 países (26%)	Primaria ≈ 103%, pero SecBaja cae a 51–54% y SecAlta a 29–33%. Ruptura drástica en la transición a secundaria.	África Subsahariana, Asia Meridional, algunos países de Oceanía
RUIDO DBSCAN — Perfiles atípicos	31 países (15%)	Perfiles únicos: extremadamente bajos (Somalia, South Sudan), o micro-territorios con datos inusuales (Monaco, Tokelau).	Dispersos geográficamente: desde Oceanía hasta Europa Occidental.

Tabla 9.1 — Perfiles educativos identificados por los métodos de aprendizaje no supervisado.

Un hallazgo clave es que la brecha entre países no está en la educación primaria (ambos clusters tienen tasas similares, $\approx 103\text{--}105\%$), sino en la TRANSICIÓN a la secundaria. Los países del Cluster 1 logran matricular a sus niños en primaria, pero pierden a más de la mitad antes de completar la secundaria baja, y casi dos tercios antes de la secundaria alta.

9.3 Diferencias Clave entre los Modelos

Aspecto	K-Means — lo que aporta	DBSCAN — en qué difiere
Número de grupos	Fuerza exactamente $k=2$ grupos	2 grupos densos + 31 outliers sin grupo
Tratamiento de Somalia	Asignado al Cluster 1 (baja cobertura)	Marcado como RUIDO: perfil único, demasiado extremo
Tratamiento de Monaco	Asignado al Cluster 0 (alta cobertura)	Marcado como RUIDO: micro-estado con patrón inusual
Interpretabilidad de resultados	Alta: perfiles medios directamente interpretables	Media: clusters más homogéneos pero listado de outliers requiere análisis caso a caso
Calidad de la separación	Silhouette=0.4833, suficiente pero mejorable	Silhouette=0.5328, mejor (sin outliers que "ensucias" los clusters)

Tabla 9.2 — Diferencias concretas entre K-Means y DBSCAN para los datos de la UNESCO.

9.4 Limitaciones y Trabajo Futuro

Limitaciones del análisis actual

- Datos faltantes imputados: 1 país fue eliminado y los valores faltantes restantes se imputaron con medianas. Esto puede suavizar diferencias reales entre países con poca cobertura de datos.
- Tasas brutas vs. netas: las tasas brutas pueden superar el 100% e incluyen repitentes y estudiantes fuera del rango etario. Las tasas netas (solo estudiantes en edad oficial) darían una comparación más precisa de acceso real.
- PCA asume linealidad: si las relaciones entre indicadores son no lineales, PCA pierde estructura. tSNE la captura visualmente, pero no permite cuantificarla.
- DBSCAN es sensible a parámetros: aunque el grid search mitiga este problema, no lo elimina completamente. Pequeños cambios en ϵ pueden mover países entre "cluster" y "ruido".
- Solo 6 variables educativas: el análisis se basa exclusivamente en tasas de matrícula. Indicadores como tasas de finalización, calidad educativa (PISA), inversión pública o infraestructura darían un perfil más completo.
- Sin variables socioeconómicas: el PIB per cápita, el Índice de Desarrollo Humano (IDH) o el nivel de urbanización mejorarían significativamente la interpretación de los clusters.

Próximos pasos a futuro

- Hierarchical Clustering (Ward, Complete): explorar dendrogramas para ver si la estructura de k=2 es estable o hay subestructuras a k=3–4 dentro de cada cluster.
- Gaussian Mixture Models (GMM): alternativa probabilística a K-Means que permite clusters de forma elíptica y da probabilidades de pertenencia en lugar de asignaciones duras.
- Integración de datos socioeconómicos: combinar los indicadores UNESCO con datos del Banco Mundial (PIB, IDH) para ver si los clusters educativos corresponden a clusters de desarrollo económico.
- Análisis temporal: en lugar de promediar sobre 2000–2022, analizar la evolución temporal de los clusters para identificar países en transición entre perfiles.
- Análisis de outliers de DBSCAN: hacer un análisis detallado caso a caso de los 31 países marcados como ruido para identificar patrones comunes que expliquen su atipicidad.

Fortalezas del análisis	Debilidades del análisis
Dataset oficial UNESCO con cobertura global (207 países)	Solo 6 variables numéricas de una dimensión
4 métodos complementarios con validación cruzada	Imputación con medianas puede perder información
91.3% varianza explicada con PCA en 2 dimensiones	Sin variables socioeconómicas de contexto
Métricas cuantitativas + validación visual (t-SNE)	t-SNE no reproducible sin random_state fijo
Grid search riguroso para parámetros DBSCAN	Tasas brutas distorsionan comparación en algunos casos

Tabla 9.3 — Balance final: fortalezas y debilidades del análisis realizado.